



7 A 11 NOVEMBRO 2023

INSTITUTO FEDERAL CATARINENSE

IFC CAMPUS BRUSQUE



<https://www.even3.com.br/facchu2023/>

INTELIGÊNCIA ARTIFICIAL DE MONITORAMENTO - IFC

Abraão Teixeira Da Silva - IFC - (abraaoteixeira0101@gmail.com);

Denis Contini - IFC - (denis.contini@ifc.edu.br);

Fabio Lamartine Barbosa Toledo - IFC - (fabio.toledo@ifc.edu.br).

RESUMO

Este estudo concentra-se no desenvolvimento de uma solução de Inteligência Artificial (IA) para monitoramento, visando criar um sistema automatizado de baixo custo, ideal para escolas públicas onde a presença constante de guardas não é sempre viável. Utilizou-se uma abordagem de aprendizado profundo, baseada no modelo YOLO (You Only Look Once), para processamento e classificação em tempo real de objetos, como armas de fogo e armas brancas. O treinamento do modelo foi realizado com um conjunto de dados público, resultando em uma precisão notável de 94% na detecção de padrões de imagem. Esta pesquisa contribui significativamente para a segurança em ambientes educacionais, com uma ênfase especial na realidade do Instituto Federal Catarinense (IFC).

Palavras-chave: Inteligência Artificial, Monitoramento, Segurança, Escolas Públicas, IFC.

1 INTRODUÇÃO

O Instituto Federal Catarinense (IFC) enfrenta os mesmos desafios crescentes relacionados à segurança que afetam o cenário educacional contemporâneo em todo o país. Recentemente, observou-se um aumento preocupante de incidentes, que vão desde vandalismo até situações mais graves, como a presença de armas no ambiente escolar. Esses eventos demandam soluções inovadoras e eficazes para garantir a integridade física e emocional de alunos, professores e demais membros da comunidade escolar.

Nesse contexto, a aplicação de Inteligência Artificial (IA) no campo de monitoramento surge como uma resposta promissora. A evolução tecnológica proporciona a disponibilidade de recursos mais acessíveis, viabilizando a implementação de sistemas de vigilância inteligentes, capazes de atuar em tempo real e com alta precisão. A presente pesquisa propõe a utilização do modelo YOLO (You Only Look Once) como base para o desenvolvimento de uma solução de monitoramento automatizado, visando mitigar os desafios de segurança em escolas públicas, com um foco especial na realidade do IFC.

A necessidade de uma abordagem como esta é ainda mais evidente quando consideramos a realidade de escolas situadas em áreas onde a presença de guaritas e vigilantes armados é inviável devido a restrições orçamentárias. Portanto, o desenvolvimento de uma solução eficaz, de baixo custo monetário e computacional, se mostra crucial para garantir a segurança e a tranquilidade no ambiente educacional do IFC.

Além disso, é importante ressaltar que a aplicação dessa tecnologia não se restringe apenas ao contexto escolar. A proposta aqui apresentada possui potencial de ser adaptada e implementada em diversos setores, como segurança pública, indústria e saúde, especialmente em instituições de cunho público, ampliando assim o alcance e a relevância desta pesquisa.

Diante do exposto, este estudo se mostra não apenas oportuno, mas também imprescindível, contribuindo de maneira significativa para a construção de ambientes educacionais mais seguros no IFC e promovendo o avanço no campo de monitoramento por meio da aplicação de Inteligência Artificial. Este tópico será desenvolvido ao longo do artigo, apresentando uma fundamentação sólida que respalda a relevância e a necessidade desta pesquisa.

2 DESENVOLVIMENTO

2.1 REFERENCIAL TEÓRICO

Conforme definições apresentadas por Russell & Norvig (2013), a inteligência artificial (IA) consiste na habilidade de construir máquinas capazes de realizar atividades que, até então, exigiam a inteligência de seres humanos. Esta área é considerada uma das temáticas mais recentes dentro das ciências exatas e da engenharia. Por muito tempo, a elaboração de um sistema de reconhecimento de padrões ou aprendizado de máquina exigia uma engenharia cuidadosa e considerável experiência de domínio para projetar um extrator de recursos que transformasse os dados brutos (pixel de uma imagem, por exemplo) em uma representação interna adequada ou vetor de recursos a partir do qual o subsistema de aprendizagem, geralmente um classificador, pode detectar ou classificar padrões na entrada (LeCun; Bengio; Hinton, 2015).

Nesse contexto, a arquitetura do YOLO é bastante útil, tendo em vista que é baseada em uma ideia simples: em vez de tratar a detecção de objetos como uma tarefa de classificação, o YOLO a trata como um problema de regressão. Isso significa que o YOLO divide a imagem de entrada em uma grade de célula e prevê as coordenadas e as classes dos objetos dentro de cada célula. Essa abordagem permite que o YOLO processe a imagem inteira como um todo, em vez de extrair regiões de interesse (ROIs) e aplicar classificadores separados para cada ROI, fato que torna o YOLO mais rápido e eficiente do que outros métodos baseados em ROIs, como o R-CNN, o Fast R-CNN e o Faster R-CNN (Redmon, 2016).

2.2 METODOLOGIA E RESULTADOS

Neste trabalho, optou-se pelo uso do YOLO, que é uma família de modelos de detecção de objetos em tempo real que se baseiam em redes neurais convolucionais. Além disso, foram preparados e carregados um conjunto de dados personalizados no formato YOLO, com imagens e anotações dos objetos de interesse, como alunos, professores e armas.

O conjunto de dados tem um arquivo YAML que indica os caminhos das imagens de treino, validação e teste, além dos nomes das classes. Os experimentos se basearam no exemplo de conjunto de dados COCO8, disponível no repositório do HUBUltralytics, contando com um dataset com 12.102 imagens, das quais eram: Facas 3.984, Pistolas 5.118, Rifles 9.306 e Nerfs 2.214, separadas em classes para a detecção.

Para implementação e execução dos algoritmos, foi utilizado o Google Colab (<https://colab.research.google.com/>), uma plataforma de computação em nuvem que

possibilita executar código Python e acessar recursos de hardware como GPUs e TPUs. A partir disso, iniciaram-se os treinos de um modelo YOLO no conjunto de dados personalizado, usando o HUBUltralytics, uma biblioteca que disponibiliza ferramentas para treinar, avaliar e implantar modelos YOLO e que permite agrupar o modelo e os dados de treinamento em um único arquivo, facilitando o processo de treinamento e implantação.

Durante os testes, foram utilizadas diferentes versões e arquiteturas do YOLO, como YOLOv5 e YOLOv8, os quais tiveram seus hiperparâmetros ajustados conforme os requisitos necessários (Terven, 2023).

Para testes onde o YOLOv5 foi utilizado para demonstrar a eficácia na detecção e a fácil modificação para a resolução do problema, o modelo apresenta-se flexível para modificações nos hiperparâmetros, além de permitir codificação em Python ou Cython. Dessa forma, antes da mudança para a versão 8 (YOLOv8), foi possível utilizar alguns códigos de otimização, com enfoque para a utilização em dispositivos com baixo poder computacional.

Ainda na condução dos experimentos, foram aplicadas 50 Épocas no modelo YOLOv8. Em contraste com o modelo YOLOv5, foram necessárias 100 Épocas para alcançar os mesmos pesos e eficiência nos vieses.


A avaliação dos resultados foi realizada utilizando métricas padrão na área de detecção de objetos (Visão Computacional):

- *mAP50 (Mean Average Precision at IoU=0.50)*: Esta métrica indica a precisão média do modelo ao detectar objetos, considerando uma sobreposição mínima de 50% entre a caixa delimitadora predita e a verdadeira. Neste experimento, obteve-se um valor de 0,931, demonstrando uma alta precisão nas detecções.
- *mAP50-9 (Variação da média de precisão em diferentes níveis de sobreposição)*: Métrica utilizada para expansão da análise ao considerar uma gama de limiares de sobreposição (IoU) de 0,50 a 0,95 com um passo de 0,05. No experimento, obteve-se um valor de 0,731, indicando a habilidade do modelo em manter uma precisão razoável alta em uma variedade de cenários.
- *Precision (Precisão)*: Mede-se a proporção de verdadeiros positivos em relação ao total de predições positivas feitas pelo modelo. Neste caso, obteve-se uma precisão de 0,929, o que sugere uma baixa taxa de falsos positivos.
- *Recall (Revocação)*: Avalia a capacidade do modelo em detectar todos os objetos verdadeiros na cena. Nesta avaliação, obteve-se um valor de 0,863, indicando uma capacidade notável de recuperar objetos relevantes.

O Gráfico abaixo, representado pela Figura 1, apresenta o desempenho do modelo YOLOv8 em relação ao número de Épocas, evidenciando um aumento gradativo da eficiência do modelo com o passar do tempo de treinamento (Épocas). Destaca-se que após a 40ª época, o modelo atingiu uma estabilização, ao contrário do YOLOv5.

A etapa de exportação do modelo treinado para uma implementação efetiva é um passo de extrema importância, especialmente considerando as diferentes necessidades que cada tipo de escola pode apresentar. Para tal, optamos por empregar o HUBUltralytics, uma plataforma que oferece uma gama variada de opções de integração para modelos treinados. Essa escolha se traduz em flexibilidade na execução, abrangendo diversas alternativas como TensorFlow, ONNX, OpenVINO, CoreML ou PaddlePaddle, assegurando, assim, a adaptação a uma ampla variedade de ambientes.

Figura 1 - Gráfico da métricas do treinamento com YOLOv8

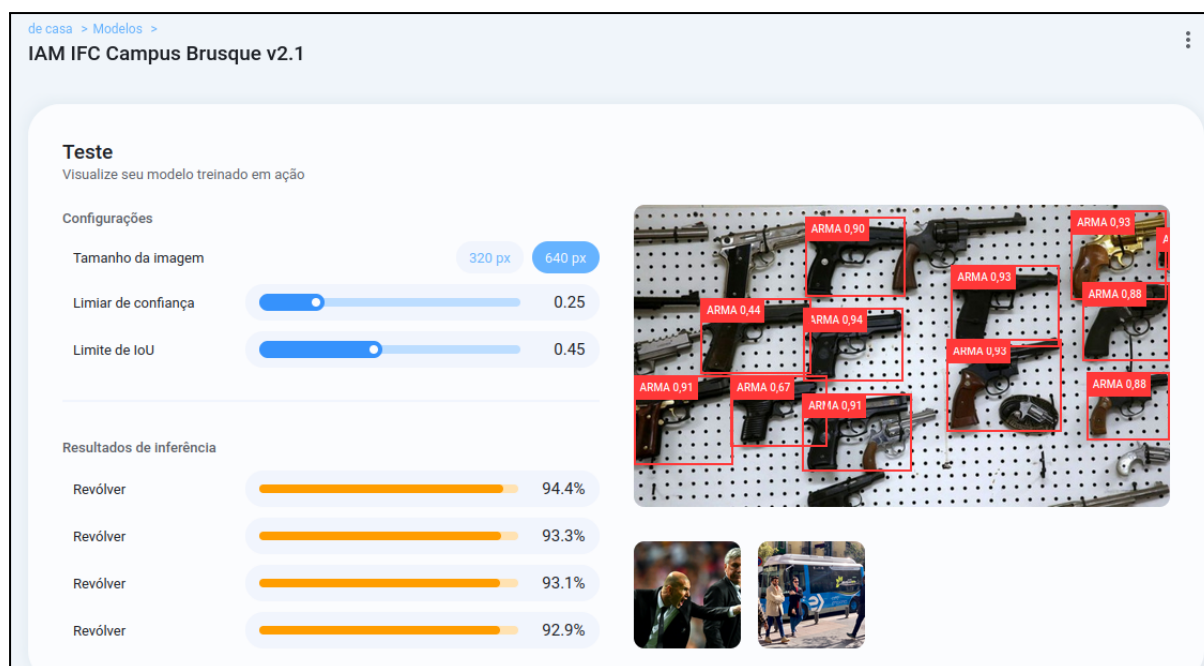


Fonte: Plataforma HubUltralytics (2023).

Para a aplicação futura do modelo treinado no contexto deste trabalho, o protocolo RTSP, ou Protocolo de Transmissão de Tempo Real, sobressai-se pela capacidade de transmitir vídeo em tempo real diretamente das câmeras de segurança distribuídas pelo campus, através dos DVRs, que permitem a ativação do RTSP para o streaming de vídeo em tempo real, podendo-se estabelecer uma ponte com o ambiente físico (Lee, 2022). A partir disso é possível fazer as configurações para implementação de código via Google Colab. Pautando-se na ideia central de se utilizar o processamento na nuvem, permitindo a aplicação prática e eficaz, sem gastos monetários.

A Figura 2 abaixo demonstra a precisão do modelo ao detectar armas, evidenciando a eficiência de até 94% no processamento do modelo, em diferentes tipos de armamentos, cujas imagens foram extraídas em pesquisa de acervo livre na internet.

Figura 2 - Teste do modelo com objetos para detecção



Fonte: Modelo IAM IFC Câmpus Brusque v2.1 - HubUltralytics (2023).

3 CONCLUSÃO

O sistema proposto, em seus testes iniciais, apresentou boa acurácia na capacidade de detecção, motivando em seu aprimoramento a criação de métodos de emissão de alertas sobre possíveis situações que ofereçam riscos à vida, usando análise em tempo real, através do modelo YOLO em conjunto com o protocolo RTSP. Por se tratar de um algoritmo que trabalha com análise de imagens de vigilância, apresenta adaptabilidade a diferentes cenários graças ao uso de um conjunto de dados personalizados e ao ajuste dos hiperparâmetros do modelo.

Por fim, o sistema, quando finalizado, pode contribuir para a prevenção e o combate à violência escolar ou, ainda, em locais públicos, fornecendo informações úteis para as autoridades e os responsáveis pela segurança. Em um futuro breve, pretende-se proceder com a execução de testes para identificação de comportamentos agressivos e simulações no ambiente real com o sistema de monitoramento já existente no IFC Câmpus Brusque. Acreditamos que esta solução não só fortalece a segurança no ambiente escolar, mas também promove a integridade e o bem-estar de todos os envolvidos no processo educacional.

5 REFERÊNCIAS

FACHINA, Marcelo Augusto Monteiro; CUETO, Juan Pablo Catalán. reflexão sobre a violência escolar: um estudo de caso sobre a emblemática violência escolar no colégio estadual joão köpke. **Revista Ibero-Americana de Humanidades, Ciências e Educação**, v. 9, n. 4, p. 275-293, 2023.

JOCHER, Glenn et al., “ultralytics/yolov7: v9.0 - YOLOv7 SOTA Realtime Object Detection (v9.0)”, **Zenodo**, 2023.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. [*Deep learning*](#). **nature**, v. 521, n. 7553, p. 436-444, 2015.

LIMA, Gustavo Ramos; CIARELLI, Patrick Marques; ESPIRITO SANTO, Vitória-ES. [Sistema de Videomonitoramento com Identificação de Suspeitos Utilizando Biometria Facial](#); 2019.

LEE, Jeonghun; HWANG, Kwang-il. YOLO with adaptive frame control for real-time object detection applications. **Multimedia Tools and Applications**, v. 81, n. 25, p. 36375-36396, 2022.

PULLAKANDAM, Muralidhar et al. Weapon Object Detection Using Quantized YOLOv8. In: **2023 5th International Conference on Energy, Power and Environment: Towards Flexible Green Energy Technologies (ICEPE)**. IEEE, 2023. p. 1-5.

Russell, S. & Norvig, P. (2013). Inteligência artificial. (3a ed), Rio de Janeiro, RJ: **Elsevier**.

REDMON, Joseph et al. You only look once: Unified, real-time object detection. In: **Proceedings of the IEEE conference on computer vision and pattern recognition**. 2016. p. 779-788.

TERVEN, Juan; CORDOVA-ESPARZA, Diana. A comprehensive review of YOLO: From YOLOv1 to YOLOv8 and beyond. **arXiv preprint arXiv:2304.00501**, 2023.